

CAPM como modelo de valuación.

Estimación y evidencia empírica.

Dr. Martín Lozano <https://mlozanoqf.github.io/>

21 de February de 2026, 10:52 PM

	Fundamental	Intermedio	Especializado
Finanzas	×	×	✓
Estadística	×	✓	×
R	×	✓	×

Introducción 1/2.

El Capital Asset Pricing Model (CAPM) es uno de los marcos centrales de la teoría financiera moderna para vincular riesgo y rendimiento esperado. Su idea principal es que, en equilibrio, los inversionistas solo deben recibir compensación por el riesgo sistemático, es decir, por la parte del riesgo que no puede eliminarse diversificando y que se resume en la exposición al portafolio de mercado (β).

En términos académicos, estimar el CAPM implica evaluar si esa predicción de equilibrio aparece en los datos y si se sostiene bajo inferencia estadística rigurosa. Por eso, además de reportar parámetros, es necesario revisar la estabilidad de los resultados y usar correcciones de errores estándar que separen evidencia económica de variación muestral.

Este enfoque académico del CAPM busca contrastar si la teoría describe efectivamente los datos. En concreto, se evalúa si los activos con mayor exposición al mercado presentan mayores rendimientos esperados en exceso, si esa relación riesgo-rendimiento es aproximadamente lineal en el conjunto de carteras y si, una vez controlada la exposición al mercado, no permanecen retornos anormales sistemáticos. Con ello, el objetivo no es solo estimar parámetros, sino juzgar la validez empírica del modelo en una muestra amplia y con inferencia estadística robusta.

En el siguiente video, en cambio, usaremos un enfoque práctico: aplicar CAPM como herramienta de decisión para estimar beta, traducirla en costo de equity para valuación y usar alpha de Jensen para seguimiento de desempeño. Es decir, aquí el foco es contrastar validez del modelo; allí, convertir el modelo en insumos operativos bajo supuestos explícitos.

Introducción 2/2.

- Usaremos datos reales y tres enfoques complementarios (1) serie de tiempo; (2) sección cruzada; y (3) Fama-MacBeth, para contrastar la idea central del CAPM: el retorno esperado en exceso debe estar explicado únicamente por la exposición al factor de mercado.
- Evaluamos si el riesgo sistemático, medido por β , organiza los rendimientos esperados. Bajo el CAPM, el retorno esperado en exceso está determinado por la exposición al factor de mercado.
- Usamos 10 carteras por tamaño de EE.UU. y el factor $Mkt-RF$. Trabajamos con retornos en exceso $r_{p,t} = R_{p,t} - R_{f,t}$ y $r_{M,t} = R_{M,t} - R_{f,t}$; en la práctica, $r_{M,t}$ corresponde al factor $Mkt-RF$ de Kenneth French.
- Las series son mensuales y están expresadas en porcentajes.
- Propósito: conectar la lógica económica del CAPM con evidencia empírica y mostrar cómo correcciones estándar afectan la inferencia sin alterar la interpretación del modelo.

Paquetes.

```
1 library(lubridate)
2 library(curl)
3 library(stringr)
4 library(readr)
5 library(broom)
6 library(dplyr)
7 library(tidyr)
8 library(lmtest)
9 library(sandwich)
10 library(ggplot2)
```

Datos 1/2.

```
1  # Descarga y arma capm_data (retornos en exceso) para 10 carteras
2
3  read_size_deciles_vw <- function(url) {
4    tf <- tempfile(fileext = ".zip"); curl_download(url, tf, mode = "wb")
5    target <- str_subset(unzip(tf, list = TRUE)$Name, "Portfolios_Formed_on_ME")[1]
6    lines <- read_lines(unz(tf, target))
7    tag <- str_which(lines, "Value Weight Returns -- Monthly")[1]
8    data_lines <- gsub(",", "", lines[(tag + 1):length(lines)])
9    data_lines <- data_lines[str_detect(data_lines, "\\s*\\d{6}")]
10   cols <- c("date_ym", "leq0", "Lo30", "Med40", "Hi30", "Lo20", "Qnt2", "Qnt3", "Qnt4", "Hi20",
11            "Lo10", "Dec2", "Dec3", "Dec4", "Dec5", "Dec6", "Dec7", "Dec8", "Dec9", "Hi10")
12   read.table(text = paste(data_lines, collapse = "\n"), header = FALSE,
13             col.names = cols, colClasses = c("character", rep("numeric", 19)),
14             sep = ",", strip.white = TRUE) |>
15     mutate(date = as.Date(ymd(paste0(date_ym, "01")))) |>
16     select(date, Lo10, Dec2, Dec3, Dec4, Dec5, Dec6, Dec7, Dec8, Dec9, Hi10) |>
17     arrange(date) |>
18     distinct(date, .keep_all = TRUE)}
19
20 read_factors <- function(url) {
21   tf <- tempfile(fileext = ".zip"); curl_download(url, tf, mode = "wb")
22   target <- str_subset(unzip(tf, list = TRUE)$Name, "F-F_Research_Data_Factors")[1]
23   lines <- read_lines(unz(tf, target))
24   first <- which(str_detect(lines, "\\s*\\d{6}"))[1]
25   cn <- str_trim(str_split(lines[first - 1], ",")[1]); cn[1] <- "date_ym"
26   read_csv(paste(lines[(first - 1):length(lines)], collapse = "\n"),
27            col_names = cn,
28            col_types = cols(date_ym = col_character(),
29                             `Mkt-RF` = col_double(),
30                             RF = col_double(),
31                             .default = col_skip())) |>
32   filter(str_detect(date_ym, "\\d{6}$")) |>
33   mutate(date = as.Date(ymd(paste0(date_ym, "01")))) |>
34   select(date, `Mkt-RF`, RF) |>
35   arrange(date) |>
36   distinct(date, .keep_all = TRUE)}
```

Datos 2/2.

```
1 url_size <-  
  ↪ "https://mba.tuck.dartmouth.edu/pages/faculty/ken.french/ftp/Portfolios_Formed_on_ME_CSV.zip"  
2 url_factors <-  
  ↪ "https://mba.tuck.dartmouth.edu/pages/faculty/ken.french/ftp/F-F_Research_Data_Factors_CSV.zip"  
3  
4 size_deciles <- read_size_deciles_vw(url_size)  
5 factors <- read_factors(url_factors)  
6  
7 common_dates <- sort(intersect(size_deciles$date, factors$date))  
8 stopifnot(length(common_dates) >= 1000)  
9 last_1k_dates <- tail(common_dates, 1000)  
10 if (is.numeric(last_1k_dates)) last_1k_dates <- as.Date(last_1k_dates, origin = "1970-01-01")  
11  
12 size_last <- filter(size_deciles, date %in% last_1k_dates)  
13 fac_last <- filter(factors, date %in% last_1k_dates)  
14  
15 capm_data <- inner_join(size_last, fac_last, by = "date") |>  
16   pivot_longer(cols = Lo10:Hi10, names_to = "portfolio", values_to = "ret_pct") |>  
17   mutate(ret = ret_pct, rf = RF, mkt_excess = `Mkt-RF`, excess_ret = ret - rf) |>  
18   select(date, portfolio, excess_ret, mkt_excess, rf)  
19  
20 nrow(capm_data)      # debería ser 10000 (1000 meses x 10 carteras)
```

```
## [1] 10000
```

```
1 range(capm_data$date) # rango de fechas usado
```

```
## [1] "1942-09-01" "2025-12-01"
```

```
1 tail(capm_data)
```

```
## # A tibble: 6 x 5
```

	date	portfolio	excess_ret	mkt_excess	rf
	<date>	<chr>	<dbl>	<dbl>	<dbl>
## 1	2025-12-01	Dec5	-0.53	-0.36	0.34
## 2	2025-12-01	Dec6	-1.21	-0.36	0.34
## 3	2025-12-01	Dec7	-0.68	-0.36	0.34
## 4	2025-12-01	Dec8	0.99	-0.36	0.34
## 5	2025-12-01	Dec9	-0.92	-0.36	0.34
## 6	2025-12-01	Hi10	-0.34	-0.36	0.34

CAPM serie de tiempo (sin y con HAC).

- Estimamos $r_{p,t} = \alpha_p + \beta_p r_{M,t} + \varepsilon_{p,t}$ para 10 carteras, donde $r_{p,t}$ y $r_{M,t}$ son retornos en exceso y $r_{M,t}$ corresponde a $Mkt-RF$.
- Objetivo: obtener $\hat{\beta}_p$ y $\hat{\alpha}_p$. Comparamos errores estándar OLS con HAC Heteroskedasticity and Autocorrelation Consistent (Newey–West) para evitar inferencia optimista cuando existe autocorrelación y heterocedasticidad.
- Muestra en esta etapa: estimamos 10 regresiones (una por cartera), cada una con $T = 1000$ observaciones mensuales.

Estimación MCO.

```

1 order_port <-
  ↪ c("Lo10", "Dec2", "Dec3", "Dec4", "Dec5", "Dec6", "Dec7", "Dec8", "Dec9", "Hi10", "Mkt-RF")
2
3 # OLS base
4 capm_ts <- capm_data |>
5   filter(!is.na(excess_ret), !is.na(mkt_excess)) |>
6   group_by(portfolio) |>
7   do(tidy(lm(excess_ret ~ mkt_excess, data = .))) |>
8   ungroup() |>
9   mutate(term = recode(term, `(Intercept)` = "alpha", mkt_excess = "beta")) |>
10  select(portfolio, term, estimate, p.value) |>
11  pivot_wider(names_from = term, values_from = c(estimate, p.value)) |>
12  mutate(portfolio = factor(portfolio, levels = order_port)) |>
13  arrange(portfolio)
14
15 # OLS con SE Newey-West (puntuales iguales)
16 capm_ts_hac <- capm_data |>
17   filter(!is.na(excess_ret), !is.na(mkt_excess)) |>
18   group_by(portfolio) |>
19   group_modify(~ {
20     fit <- lm(excess_ret ~ mkt_excess, data = .x)
21     nwvc <- NeweyWest(fit, lag = 3, prewhite = FALSE) # ajusta lag (3-6 típico)
22     tidy(coeftest(fit, vcov. = nwvc))) |>
23   ungroup() |>
24   mutate(term = recode(term, `(Intercept)` = "alpha", mkt_excess = "beta")) |>
25   select(portfolio, term, estimate, p.value) |>
26   pivot_wider(names_from = term, values_from = c(estimate, p.value)) |>
27   mutate(portfolio = factor(portfolio, levels = order_port)) |>
28   arrange(portfolio)
29
30 capm_ts      # sin corrección

```

A tibble: 10 x 5

##	portfolio	estimate_alpha	estimate_beta	p.value_alpha	p.value_beta
##	<fct>	<dbl>	<dbl>	<dbl>	<dbl>
##	1 Lo10	0.154	1.15	0.247	1.23e-192
##	2 Dec2	0.0424	1.21	0.694	3.09e-266
##	3 Dec3	0.0628	1.20	0.480	0
##	4 Dec4	0.0508	1.17	0.534	0
##	5 Dec5	0.0373	1.16	0.593	0
##	6 Dec6	0.0296	1.12	0.616	0
##	7 Dec7	0.0484	1.12	0.341	0
##	8 Dec8	0.0342	1.08	0.425	0
##	9 Dec9	0.0381	1.02	0.261	0
##	10 Hi10	0.00250	0.939	0.925	0


```
1 capm_ts_hac # con SE HAC
```

```
## # A tibble: 10 x 5
```

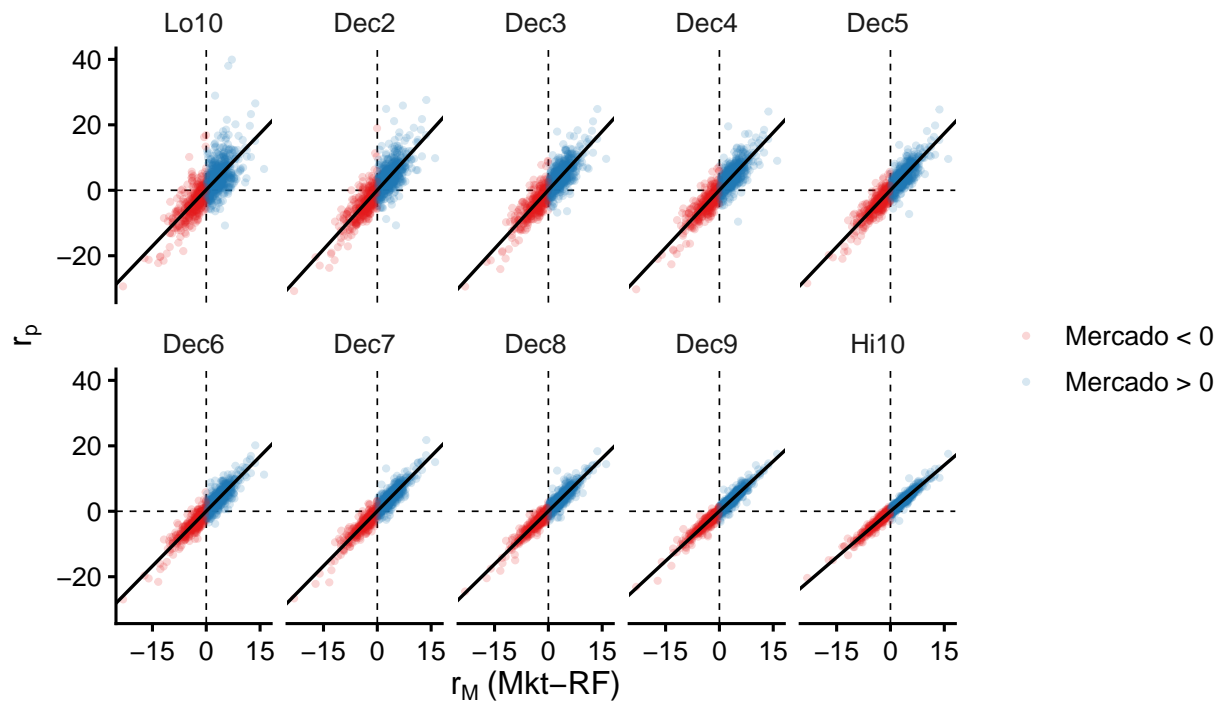
##	portfolio	estimate_alpha	estimate_beta	p.value_alpha	p.value_beta
##	<fct>	<dbl>	<dbl>	<dbl>	<dbl>
##	1 Lo10	0.154	1.15	0.266	1.06e-134
##	2 Dec2	0.0424	1.21	0.697	2.02e-213
##	3 Dec3	0.0628	1.20	0.486	2.92e-245
##	4 Dec4	0.0508	1.17	0.541	1.98e-252
##	5 Dec5	0.0373	1.16	0.586	3.62e-295
##	6 Dec6	0.0296	1.12	0.632	0
##	7 Dec7	0.0484	1.12	0.372	0
##	8 Dec8	0.0342	1.08	0.453	0
##	9 Dec9	0.0381	1.02	0.303	0
##	10 Hi10	0.00250	0.939	0.929	0

Visualización MCO.

```
1 order_port <- c("Lo10","Dec2","Dec3","Dec4","Dec5","Dec6","Dec7","Dec8","Dec9","Hi10")
2
3 line_df <- capm_ts |>
4   transmute(portfolio, alpha = estimate_alpha, beta = estimate_beta) |>
5   mutate(portfolio = factor(portfolio, levels = order_port))
6
7 capm_plot_df <- capm_data |>
8   mutate(portfolio = factor(portfolio, levels = order_port))
9
10 ggplot(capm_plot_df, aes(x = mkt_excess, y = excess_ret)) +
11   geom_hline(yintercept = 0, linetype = "dashed", linewidth = 0.3) +
12   geom_vline(xintercept = 0, linetype = "dashed", linewidth = 0.3) +
13   geom_point(aes(color = mkt_excess > 0), alpha = 0.18, size = 0.7) +
14   geom_abline(data = line_df, aes(intercept = alpha, slope = beta),
15     show.legend = FALSE, linewidth = 0.6) +
16   facet_wrap(~ portfolio, ncol = 5) +
17   scale_color_manual(values = c("TRUE" = "#1f78b4", "FALSE" = "#e31a1c"),
18     labels = c("FALSE" = "Mercado < 0", "TRUE" = "Mercado > 0"),
19     name = "") +
20   scale_x_continuous(breaks = c(-15, 0, 15)) +
21   scale_y_continuous(breaks = scales::pretty_breaks(n = 4)) +
22   labs(title = expression(atop("CAPM en exceso: serie de tiempo por cartera",
23     r[p,t] == alpha[p] + beta[p] %.% r[M,t])),
24     x = expression(r[M,t] ~ "(Mkt-RF)"),
25     y = expression(r[p,t])) +
26   theme_classic(base_size = 12) + # quita cuadrícula
27   theme(axis.text.x = element_text(angle = 0, vjust = 0.5),
28     strip.background = element_blank())
```

CAPM en exceso: serie de tiempo por cartera

$$r_p = \alpha_p + \beta_p \cdot r_M$$




Resultados. CAPM serie de tiempo (sin y con HAC).

- Las $\hat{\beta}_p$ se ubican entre 0.94 y 1.21 y son altamente significativas. En general, las carteras de mayor tamaño tienden a mostrar menor exposición al mercado.
- Las $\hat{\alpha}_p$ son pequeñas en magnitud, del orden de décimas de punto porcentual mensual, y no son estadísticamente distintas de cero. HAC (Newey–West) cambia poco la inferencia, pero protege contra autocorrelación y heterocedasticidad.

Visualización de Betas y rendimientos en exceso.

```
1 order_port <-  
  ↪ c("Lo10", "Dec2", "Dec3", "Dec4", "Dec5", "Dec6", "Dec7", "Dec8", "Dec9", "Hi10", "Mkt-RF")  
2  
3 # Totales promedio por cartera  
4 beta_ret <- capm_ts |>  
5   mutate(portfolio = factor(portfolio, levels = order_port)) |>  
6   select(portfolio, beta = estimate_beta) |>  
7   inner_join(capm_data |>  
8     group_by(portfolio) |>  
9     summarise(mean_total = mean(excess_ret, na.rm = TRUE),  
10      .groups = "drop"), by = "portfolio")  
11  
12 # Punto de mercado: beta=1, mkt_excess  
13 mkt_point <- tibble(portfolio = factor("Mkt-RF", levels = order_port),  
14   beta = 1,  
15   mean_total = mean(capm_data$mkt_excess, na.rm = TRUE))  
16  
17 beta_ret <- bind_rows(beta_ret, mkt_point)  
18  
19 ggplot(beta_ret, aes(x = beta, y = mean_total, label = portfolio)) +  
20   geom_point(size = 3, color = "#1f78b4") +  
21   geom_text(vjust = -0.8, size = 3) +  
22   labs(title = "CAPM en exceso: puntos por cartera",  
23     x = "Beta (exposición al mercado)",  
24     y = "Rendimiento promedio en exceso") +  
25   theme_minimal(base_size = 12) +  
26   scale_x_continuous(limits = c(0.9, 1.25), expand = c(0, 0)) +  
27   scale_y_continuous(limits = c(0.65, 1.05), expand = c(0, 0)) +  
28   coord_equal()
```



Regresión en sección cruzada (sin y con Shanken).

- Antes estimamos $\hat{\beta}_p$ para cada cartera a partir de una regresión de serie de tiempo. Ahora usamos esas $\hat{\beta}_p$ como insumo para evaluar la predicción central del CAPM en la sección cruzada.
- Específicamente, relacionamos el retorno promedio en exceso de cada cartera con su exposición al mercado: $\bar{r}_p = \gamma_0 + \gamma_1 \hat{\beta}_p + u_p$, donde \bar{r}_p es el promedio temporal de $r_{p,t}$.
- Interpretación: γ_1 es el precio del riesgo de mercado, la compensación promedio por una unidad adicional de β , y γ_0 es el intercepto de la relación riesgo-retorno.
- Preguntas: ¿existe una relación positiva riesgo-retorno $\gamma_1 > 0$? y ¿es el intercepto compatible con cero en retornos en exceso $\gamma_0 = 0$?
- Reportamos OLS y un ajuste estilo Shanken para reflejar que $\hat{\beta}_p$ es un regresor estimado, lo que tiende a inflar los errores estándar respecto al caso con β observada.
- Muestra en esta etapa: la regresión en sección cruzada usa $N = 10$ observaciones (una por cartera).

Estimación regresión en sección cruzada.

```
1 cross_df <- capm_ts |>
2   select(portfolio, beta = estimate_beta) |>
3   inner_join(capm_data |>
4     group_by(portfolio) |>
5     summarise(mean_excess = mean(excess_ret, na.rm = TRUE),
6       .groups = "drop"), by = "portfolio")
7
8 cs_reg <- lm(mean_excess ~ beta, data = cross_df)
9 cs_tidy <- tidy(cs_reg) # OLS sin corrección
10
11 # Shanken (corrige que beta es estimado)
12 sigma_f2 <- var(capm_data$mkt_excess, na.rm = TRUE)
13 mu_f <- mean(capm_data$mkt_excess, na.rm = TRUE)
14 shanken_fac <- 1 + (mu_f^2 / sigma_f2)
15
16 vcov_shanken <- vcov(cs_reg) * shanken_fac
17 cs_shanken <- coeftest(cs_reg, vcov. = vcov_shanken) |>
18 tidy() # estimate, std.error, statistic, p.value
19
20 cs_tidy # sin corrección
```

```
## # A tibble: 2 x 5
##   term          estimate std.error statistic  p.value
##   <chr>          <dbl>     <dbl>     <dbl>    <dbl>
## 1 (Intercept)   -0.184     0.169     -1.09  0.307
## 2 beta          0.945     0.151      6.27  0.000241
```

```
1 cs_shanken # con SE Shanken
```

```
## # A tibble: 2 x 5
##   term          estimate std.error statistic  p.value
##   <chr>          <dbl>     <dbl>     <dbl>    <dbl>
## 1 (Intercept)   -0.184     0.171     -1.08  0.313
## 2 beta          0.945     0.153      6.18  0.000266
```


Resultados. Sección cruzada de promedios (sin y con Shanken).


- El precio del riesgo γ_1 es positivo en la muestra, con $\hat{\gamma}_1 = 0.95\%$ mensual. La inferencia arroja $p = 0.000$ en OLS y $p = 0.000$ con ajuste estilo Shanken. Con estos valores, la evidencia para γ_1 es significativa al 5%.
- El intercepto γ_0 no difiere significativamente de cero, consistente con rendimientos en exceso correctamente centrados.
- Este resultado anticipa lo que veremos con Fama-MacBeth: en lugar de usar solo promedios, estimaremos el precio del riesgo mes a mes para evaluar su variación temporal y realizar inferencia con errores estándar adecuados.

Visualización de Betas, rendimientos en exceso y línea de regresión.

```
1 alpha_cs <- coef(cs_reg)[["(Intercept)"]]
2 slope_rm <- coef(cs_reg)[["beta"]]
3
4 ggplot(beta_ret, aes(x = beta, y = mean_total, label = portfolio)) +
5   geom_point(size = 3, color = "#1f78b4") +
6   geom_text(vjust = -0.8, size = 3) +
7   geom_abline(intercept = alpha_cs, slope = slope_rm,
8               linetype = "dashed", color = "firebrick") +
9   labs(title = expression(atop("CAPM en exceso: puntos por cartera y línea", E(r[p]) == alpha
10    + beta * E(r[M]))),
11         x = "Beta (exposición al mercado)",
12         y = "Rendimiento promedio en exceso") +
13   theme_minimal(base_size = 12) +
14   scale_x_continuous(limits = c(0.9, 1.25), expand = c(0, 0)) +
15   scale_y_continuous(limits = c(0.65, 1.05), expand = c(0, 0)) +
16   coord_equal()
```

CAPM en exceso: puntos por cartera y línea

$$E(r_p) = \alpha + \beta \cdot E(r_M)$$



Fama-MacBeth (sin y con Newey-West).

- Fama-MacBeth: para cada mes estimamos $r_{p,t} = \lambda_{0,t} + \lambda_{1,t}\hat{\beta}_p + \eta_{p,t}$, usando $\hat{\beta}_p$ fijas la regresión de serie de tiempo.
- Interesa el precio del riesgo $\lambda_{1,t}$ y su promedio $\bar{\lambda}_1$. Para la inferencia sobre $\bar{\lambda}_1$, comparamos errores estándar básicos con HAC (Newey-West) sobre la serie temporal de $\hat{\lambda}_{1,t}$ (y análogamente para $\hat{\lambda}_{0,t}$).
- Valor agregado frente a la sección cruzada: en lugar de estimar un solo γ_1 usando medias, Fama-MacBeth estima $\lambda_{1,t}$ mes a mes. Esto permite estudiar la variación temporal del precio del riesgo y construir inferencia a partir de la dispersión temporal de $\hat{\lambda}_{1,t}$, con correcciones HAC cuando hay dependencia en el tiempo.
- Como el punto $Mkt-RF$ es solo una referencia visual y no entra en la regresión cruzada, la recta no está obligada a pasar exactamente por él.
- Muestra en esta etapa: se estiman $T = 1000$ regresiones mensuales, cada una con $N = 10$ carteras.

Estimación Fama-MacBeth 1/2.

```
1 # Betas fijos serie de tiempo
2 betas <- capm_ts |>
3   select(portfolio, beta = estimate_beta)
4
5 # Regresiones mensuales:  $r_{p,t} \sim \beta_p$ 
6 fm_monthly <- capm_data |>
7   select(date, portfolio, ret = excess_ret) |>
8   left_join(betas, by = "portfolio") |>
9   group_by(date) |>
10  group_modify(~ tidy(lm(ret ~ beta, data = .x))) |>
11  ungroup() |>
12  mutate(term = recode(term, `(Intercept)` = "lambda0", beta = "lambda1"))
13
14 # Series 1_t y 0_t
15 lambda1_series <- fm_monthly |>
16   filter(term == "lambda1") |>
17   select(date, lambda1 = estimate, se = std.error, t = statistic, p = p.value)
18
19 lambda0_series <- fm_monthly |>
20   filter(term == "lambda0") |>
21   select(date, lambda0 = estimate, se = std.error, t = statistic, p = p.value)
22
23 # Resumen FM básico ( $sd/\sqrt{T}$ )
24 lambda1_mean_basic <- lambda1_series |>
25   summarise(estimate = mean(lambda1, na.rm = TRUE),
26             std.error = sd(lambda1, na.rm = TRUE) / sqrt(n()),
27             statistic = estimate / std.error,
28             p.value = 2 * pt(-abs(statistic), df = n() - 1)) |>
29   mutate(method = "FM básico", factor = "lambda1", nw_lag = NA_integer_) |>
30   select(method, factor, estimate, std.error, statistic, p.value, nw_lag)
31
32 lambda0_mean_basic <- lambda0_series |>
33   summarise(estimate = mean(lambda0, na.rm = TRUE),
34             std.error = sd(lambda0, na.rm = TRUE) / sqrt(n()),
35             statistic = estimate / std.error,
36             p.value = 2 * pt(-abs(statistic), df = n() - 1)) |>
37   mutate(method = "FM básico", factor = "lambda0", nw_lag = NA_integer_) |>
38   select(method, factor, estimate, std.error, statistic, p.value, nw_lag)
```

Estimación Fama-MacBeth 2/2.

```

1  # Resumen FM con Newey-West sobre las series
2  nw_L <- 3 # rezago HAC (3-6 típico en mensual)
3
4  lambda1_mean_nw <- {
5    fit <- lm(lambda1 ~ 1, data = lambda1_series)
6    vc <- NeweyWest(fit, lag = nw_L, prewhite = FALSE)
7    coeftest(fit, vcov. = vc) |>
8      tidy() |>
9      transmute(method = "FM + NW", factor = "lambda1",
10                estimate = estimate, std.error = std.error,
11                statistic = statistic, p.value = p.value,
12                nw_lag = nw_L)}
13
14  lambda0_mean_nw <- {
15    fit <- lm(lambda0 ~ 1, data = lambda0_series)
16    vc <- NeweyWest(fit, lag = nw_L, prewhite = FALSE)
17    coeftest(fit, vcov. = vc) |>
18      tidy() |>
19      transmute(method = "FM + NW", factor = "lambda0",
20                estimate = estimate, std.error = std.error,
21                statistic = statistic, p.value = p.value,
22                nw_lag = nw_L)}
23
24  # Comparación lado a lado
25  lambda_mean <- bind_rows(lambda1_mean_basic, lambda0_mean_basic,
26                            lambda1_mean_nw, lambda0_mean_nw)
27
28  lambda1_series # serie mensual de 1_t

```

```

## # A tibble: 1,000 x 5
##   date      lambda1    se      t      p
##   <date>      <dbl> <dbl> <dbl> <dbl>
## 1 1942-09-01   12.9  13.4  0.965 0.363
## 2 1942-10-01   22.7   5.22  4.36 0.00242
## 3 1942-11-01  -14.4   5.17 -2.79 0.0235
## 4 1942-12-01  -16.5   8.12 -2.03 0.0765
## 5 1943-01-01   70.7  35.8   1.97 0.0840
## 6 1943-02-01   50.7  36.2   1.40 0.198
## 7 1943-03-01   36.0  10.5   3.44 0.00878
## 8 1943-04-01   26.3  10.9   2.41 0.0426
## 9 1943-05-01   34.6  17.9   1.94 0.0883
## 10 1943-06-01  -8.74  7.74 -1.13 0.292
## # i 990 more rows

```

```
1 lambda0_series # serie mensual de 0_t
```

```
## # A tibble: 1,000 x 5
##   date      lambda0    se      t      p
##   <date>      <dbl> <dbl> <dbl> <dbl>
## 1 1942-09-01  -10.0 14.9  -0.673 0.520
## 2 1942-10-01  -15.6  5.83 -2.67  0.0284
## 3 1942-11-01   14.3  5.78  2.47  0.0385
## 4 1942-12-01   22.1  9.07  2.43  0.0409
## 5 1943-01-01  -63.2 40.1  -1.58  0.153
## 6 1943-02-01  -43.7 40.4  -1.08  0.311
## 7 1943-03-01  -29.5 11.7  -2.52  0.0356
## 8 1943-04-01  -25.2 12.2  -2.07  0.0727
## 9 1943-05-01  -29.1 20.0  -1.46  0.182
## 10 1943-06-01   10.3  8.65  1.20  0.266
## # i 990 more rows
```

```
1 lambda_mean # tabla comparativa básica vs NW para 0 y 1
```


```
## # A tibble: 4 x 7
##   method    factor estimate std.error statistic p.value nw_lag
##   <chr>      <chr>      <dbl>      <dbl>      <dbl>      <dbl> <dbl>
## 1 FM básico lambda1    0.945      0.484      1.95      0.0512 NA
## 2 FM básico lambda0   -0.184      0.466     -0.395     0.693 NA
## 3 FM + NW   lambda1    0.945      0.521      1.81      0.0701 3
## 4 FM + NW   lambda0   -0.184      0.480     -0.383     0.702 3
```

Visualización de las estimaciones Fama-MacBeth.

```
1 lambda_year <- bind_rows(  
2   lambda1_series |> transmute(date, value = lambda1, factor = "hat(lambda)[1]"),  
3   lambda0_series |> transmute(date, value = lambda0, factor = "hat(lambda)[0]")  
4 ) |>  
5   mutate(year = year(date)) |>  
6   group_by(factor, year) |>  
7   summarise(value = mean(value, na.rm = TRUE), .groups = "drop")  
8  
9   # Medias por panel (para la línea vertical)  
10 lambda_year_mean <- lambda_year |>  
11   group_by(factor) |>  
12   summarise(mu = mean(value, na.rm = TRUE), .groups = "drop")  
13  
14 ggplot(lambda_year, aes(x = value)) +  
15   geom_density(aes(fill = factor), alpha = 0.35, adjust = 1.1, linewidth = 0.8) +  
16   geom_vline(data = lambda_year_mean, aes(xintercept = mu),  
17             linetype = "solid", linewidth = 0.6) +  
18   facet_wrap(~ factor, scales = "free_x", ncol = 1, labeller = label_parsed) +  
19   scale_x_continuous(breaks = scales::breaks_width(2)) +  
20   labs(title = "Fama-MacBeth: densidad de promedios anuales",  
21        subtitle = "Línea sólida: media por panel",  
22        x = "Promedio anual", y = "Densidad") +  
23   theme_classic(base_size = 13) +  
24   theme(legend.position = "none",  
25         strip.text = element_text(size = 16),  
26         strip.background = element_blank())
```

Fama–MacBeth: densidad de promedios anuales

Línea sólida: media por panel



Resultados. Fama-MacBeth (sin y con Newey-West).

- El precio del riesgo de mercado es positivo en promedio y coherente con la sección cruzada. La evidencia estadística es moderada, con $p = 0.051$ en FM básico y $p = 0.070$ con HAC Newey-West.
- En magnitud económica, el estimado central es $\bar{\lambda}_1 = 0.95\%$ mensual.
- El intercepto promedio es $\bar{\lambda}_0 = -0.18\%$ y no es estadísticamente distinto de cero ($p = 0.693$ básico; $p = 0.702$ HAC); la corrección Newey-West aumenta modestamente los errores estándar sin cambiar el mensaje central.

Conclusión.

- En esta muestra, con 10 carteras y 1000 meses, la evidencia es consistente con la predicción central del CAPM: a mayor exposición al mercado, medida por β , mayor rendimiento esperado en exceso.
- El precio del riesgo de mercado se estima en $\hat{\lambda}_1 = 0.95\%$ mensual. En aproximación lineal, esto equivale a 11.34% anual. La significancia es marginal: $p = 0.051$ en FM básico y $p = 0.070$ con HAC.
- En términos económicos, diferencias moderadas en exposición al mercado se traducen en diferencias relevantes de retorno esperado. Por ejemplo, una cartera con $\beta = 1.20$ frente a otra con $\beta = 0.90$ tendría una prima esperada adicional de 0.28% mensual. En aproximación lineal, esto equivale a 3.40% anual.
- Los interceptos, o alphas, son pequeños y no muestran desvíos sistemáticos de cero. Esto sugiere que, dentro de esta muestra, el factor de mercado captura la parte principal de la prima por riesgo.
- El resultado debe leerse como evidencia favorable, no como validación definitiva. El buen ajuste puede depender del diseño muestral, con carteras diversificadas y horizonte largo, y modelos multifactor pueden explicar variación adicional en rendimientos.

Enfoque	Resultado clave	Lectura
Serie de tiempo	$\hat{\beta}$ en $[0.94, 1.21]$.	Betas significativas y alphas pequeños
Sección cruzada	$\hat{\gamma}_1 = 0.95\%$; p Shanken = 0.000.	Relación riesgo-retorno positiva
Fama-MacBeth	$\hat{\lambda}_1 = 0.95\%$; p FM+NW = 0.070.	Signo positivo con evidencia moderada al ajustar dependencia temporal